

PROJECT MACHINE LEARNING

**“Penerapan Algoritma Random Forest untuk Menganalisis Tingkat Kemiskinan
Kabupaten/Kota di Indonesia”**



DISUSUN OLEH:

Tulus Ramadhany (G1F02310007)

Ersa Iqima Qur'anul Ain (G1F02310031)

Muhammad Adam Rijaldin (G1F20310035)

**PROGRAM STUDI STATISTIKA
FAKULTAS MATEMATIKA DAN ILMU PENGETAHUAN ALAM
UNIVERSITAS MATARAM**

2025

BAB I

PENDAHULUAN

1.1 Abstrak

Penelitian ini bertujuan untuk menganalisis tingkat kemiskinan di Indonesia menggunakan pendekatan Machine Learning. Data cross-section tahun 2023 dari Badan Pusat Statistik (BPS) untuk 479 kabupaten/kota di Indonesia digunakan, mencakup variabel persentase penduduk miskin sebagai variabel target, serta Produk Domestik Regional Bruto (PDRB), Indeks Pembangunan Manusia (IPM), Tingkat Pengangguran Terbuka (TPT), dan Rata-rata Lama Sekolah (RLS) sebagai variabel prediktor. Metode Random Forest Regression diterapkan sebagai teknik pemodelan. Proses pra-pengolahan data meliputi Exploratory Data Analysis (EDA), penanganan *missing value* (imputasi median untuk variabel TPT), standarisasi data, dan pembagian data menjadi set pelatihan (80%) dan pengujian (20%). Meskipun outlier terdeteksi pada beberapa variabel (terutama PDRB), mereka dipertahankan untuk menjaga integritas dan representativitas data ekonomi dan sosial. Optimasi model dilakukan melalui *hyperparameter tuning* menggunakan Randomized Search CV. Hasil analisis korelasi menunjukkan hubungan positif yang kuat antara IPM dan RLS, serta korelasi negatif yang signifikan antara kemiskinan dengan IPM dan RLS. Model Random Forest yang telah di-tuning menunjukkan performa dengan nilai MAE 0.60, RMSE 0.78, dan R^2 0.40, mengindikasikan bahwa model mampu menjelaskan sekitar 40% variasi tingkat kemiskinan. Hasil penelitian menunjukkan bahwa IPM dan RLS merupakan variabel yang paling signifikan dalam memengaruhi variasi tingkat kemiskinan. Selain itu, penerapan metode Machine Learning, khususnya Random Forest, mampu mengakomodasi kompleksitas hubungan antarvariabel sosial-ekonomi sehingga memberikan pemodelan yang lebih komprehensif dan informatif.

Kata Kunci: Kemiskinan, Machine Learning, Random Forest Regression, PDRB, IPM, TPT, RLS.

1.2 Latar Belakang

Kemiskinan merupakan kata yang tidak pernah berhenti diperdebatkan kalangan intelektual, akademisi, praktisi Lembaga Swadaya Masyarakat (LSM), birokrat, dan mahasiswa disebabkan oleh dampak luar biasa yang dihadirkan oleh kemiskinan tersebut. Kemiskinan menyebabkan hilangnya: (a) kesejahteraan bagi kalangan miskin (sandang, pangan, dan papan), (b) hak akan pendidikan, (c) hak atas kesehatan, (d) tersingkirnya dari pekerjaan layak secara kemanusiaan, (e) termarginalkan dari hak atas perlindungan hukum, (f) hak atas rasa aman, (g) hak atas partisipasi terhadap pemerintah dan keputusan publik, (h) hak atas spiritualitas, (i) hak untuk berinovasi, dan yang lebih penting (j) hak atas kebebasan hidup (Zahrawati F., (2020).

Salah satu merupakan penanda yang wajib guna mengenali keadaan ekonomi di suatu daerah/regional dalam sesuatu masa tertentu ialah Produk Domestik Regional Bruto (PDRB), baik menurut ketentuan harga berlaku ataupun menurut ketentuan harga konstan. PDRB pada umumnya adalah keseluruhan nilai tambah yang didapatkan dari segala unit usaha dalam sesuatu daerah tertentu, atau menggambarkan keseluruhan nilai barang serta jasa akhir yang didapatkan oleh segala aspek ekonomi. Produk Domestik Regional (PDRB) pada tingkatan daerah (provinsi/kabupaten/kota) melambangkan keahlian suatu daerah guna menghasilkan output pada sesuatu waktu tertentu. Guna membentuk PDRB dipakai dua pendekatan, ialah produksi dan penggunaan. Keduanya menyuguhkan bahanbahan information nilai tambah dirinci bagi sumber aktifitas ekonomi (lapangan usaha) serta bagi unsur kegunaannya (Hasibuan, R. R. A., et al).

Pembangunan manusia adalah sebuah proses dan hasil yaitu proses memperbesar pilihan orang tetapi juga menjadi tujuan. Pembangunan manusia mengimplikasikan bahwa orang harus mempengaruhi proses yang membentuk

kehidupan mereka. Pertumbuhan ekonomi merupakan sarana penting bagi pembangunan manusia, namun tidak pada akhirnya. Pembangunan manusia adalah pengembangan masyarakat melalui pembangunan kemampuan manusia, oleh masyarakat melalui partisipasi aktif dalam proses yang membentuk kehidupan dan masyarakat dengan memperbaiki kehidupan mereka. Ini lebih luas daripada pendekatan lain, seperti pendekatan sumber daya manusia, pendekatan kebutuhan dasar dan pendekatan kesejahteraan manusia. Indeks Pembangunan Manusia gabungan (IPM) mengintegrasikan tiga dimensi dasar pembangunan manusia (Siswati, E., et al, 2018).

Indonesia ialah sebuah negara berkembang, memiliki beragam persoalan yang dialami, salah satunya ialah tingginya taraf pengangguran yang ada di negara ini. Pengangguran di Indonesia mencapai angka diatas 5% setiap tahunnya. ingkat pengangguran di Indonesia harus segera di atasi karena dapat menimbulkan peningkatan kemiskinan di Indonesia. Tingginya angka pengangguran di sebabkan banyaknya permintaan perusahaan atau lapangan pekerjaan yang tidak sesuai dengan mereka para pencari pekerja, banyaknya perusahaan yang mencari lulusan diploma ataupun sarjana. Karenanya pengangguran merupakan pertanggung jawaban kolektif, terlebih lagi pemerintah untuk bisa mencari solusi supaya menekan angka pengangguran yang terdapat di Indonesia. Pada tahun 2020 dapat kita liat bahwasanya terdapat sejumlah daerah yang bertaraf pengangguran melampaui taraf pengangguran nasional misalnya : DKI Jakarta 10,95%, Banten 10,64%, Jawa Barat 10,46%, Maluku, 7,57%, Sulawesi Utara, 7,37%, Kalimantan Timur, 6,87%, Jawa Tengah, 6,48%, Aceh 6,59%, Sumatera Utara, 6,91%, Sumatera Barat, 6,88%, Sulawesi Selatan 6,31%, Papua Barat, 6,80%. Tingginya taraf pengangguran bisa kesuksesan pembangunan ekonomi. Hal tersebut dikarenakan pengangguran adalah parameter penting guna dibahas, karna berkaitan erat dengan variabel ekonomi lainnya (Ardian, R., et al).

Pendidikan juga merupakan faktor penting yang dapat meningkatkan pertumbuhan ekonomi. Karena Pendidikan dianggap memiliki peranan dalam

menentukan kualitas manusia. Dalam kaitannya dengan perekonomian secara nasional, semakin tinggi kualitas hidup suatu bangsa, maka akan semakin tinggi pertumbuhan dan kesejahteraan bangsa tersebut (Arifin, 2019). Berdasarkan data Badan Pusat Statistik rata-rata lama sekolah di Provinsi DIY terjadi peningkatan yaitu dari 8.51 di tahun 2010 menjadi 9.55 di tahun 2020 atau setara dengan lulusan Sekolah Menengah Pertama (SMP). Meskipun mengalami peningkatan, capaian angka rata-rata lama sekolah penduduk DIY masih rendah dan belum menamatkan pendidikan Sekolah Menengah Atas (SMA) serta belum mencapai target pendidikan 15 tahun yang telah diusulkan United National Development Program (UNDP). Dengan ini semakin tinggi tingkat pendidikan seseorang, maka pengetahuan dan keahlian juga akan semakin meningkat sehingga akan mendorong peningkatan terhadap produktivitas seseorang (Putriana, R., & Aji, R. H. S., 2022).

Machine learning, sebagai salah satu cabang dari kecerdasan buatan, telah menjadi pendorong utama inovasi teknologi di berbagai bidang. Teknologi ini memungkinkan sistem untuk mempelajari pola dan struktur dari data, yang kemudian digunakan untuk membuat prediksi atau keputusan secara otomatis. Dalam dekade terakhir, peningkatan kemampuan perangkat keras dan ketersediaan data yang melimpah telah mendorong adopsi machine learning di berbagai sector. Machine Learning dapat mengoptimalkan proses pengambilan keputusan dengan menyajikan *insight* yang bersifat prediktif dan berjalan secara otomatis. Pembelajaran mesin/Machine Learning adalah studi berkelanjutan tentang konsep pengenalan pola dan pembelajaran komputasi dalam kecerdasan buatan yang menggunakan algoritma pembelajaran seperti diawasi dan tidak diawasi untuk memprediksi dan mendukung pengambilan keputusan otomatis berdasarkan sekumpulan data

Random Forest (RF) pertama kali diperkenalkan oleh Leo Breiman (2001). RF merupakan salah satu metode yang dapat meningkatkan hasil akurasi dalam membangkitkan atribut untuk setiap node yang dilakukan secara acak. RF terdiri dari sekumpulan decision tree, dimana kumpulan pohon

keputusan ini digunakan untuk mengklasifikasi data ke suatu kelas. Pohon keputusan dibuat dengan menentukan node akar dan berakhir dengan beberapa node daun untuk mendapatkan hasil akhir. Algoritma Random Forest merupakan sekumpulan pohon keputusan (decision tree) yang dapat digunakan untuk melakukan klasifikasi dan prediksi. Pada metode Random Forest tidak terdapat pruning atau pemangkasan variabel seperti yang terjadi pada Decision Tree. Random Forest menerapkan metode bootstrap aggregating (bagging) dan random feature selection. Bagging merupakan suatu metode yang dapat digunakan untuk memperbaiki hasil yang diperoleh dari algoritma klasifikasi.

BAB II

TINJAUAN PUSTAKA

Penelitian mengenai pemodelan dan prediksi kemiskinan dengan pendekatan *machine learning* menunjukkan perkembangan yang pesat dalam pemanfaatan data sosial ekonomi untuk mendukung perumusan kebijakan publik. Berbagai algoritma seperti Random Forest, K-Nearest Neighbors (KNN), XGBoost, serta model ensemble lainnya terbukti mampu menangani pola non-linear, interaksi antarvariabel, serta memberikan prediksi yang lebih stabil dibanding metode statistik tradisional. Kemampuan ini menjadikan pendekatan *machine learning* semakin relevan untuk menganalisis fenomena kemiskinan yang bersifat multidimensional.

Penelitian oleh Ernawati et al. (2025) menerapkan algoritma Random Forest dan KNN untuk klasifikasi status kemiskinan penduduk di Labuhanbatu. Hasil penelitian menunjukkan bahwa Random Forest memiliki performa sedikit lebih baik dibanding KNN, meskipun selisihnya tidak signifikan. Keunggulan Random Forest terlihat dari kemampuannya menangani variabel sosial ekonomi dalam jumlah besar, seperti pekerjaan, pendapatan, pendidikan, dan kondisi tempat tinggal, sehingga menghasilkan klasifikasi yang lebih stabil. Studi ini memperkuat bahwa model berbasis pohon keputusan cukup efektif untuk mengolah data sosial ekonomi yang kompleks.

Selain itu, Pratama & Astuti (2025) membandingkan Linear Regression, Random Forest, dan XGBoost dalam memprediksi jumlah penduduk miskin di Jawa Tengah. Hasil penelitian menunjukkan bahwa XGBoost menghasilkan performa terbaik dengan nilai MAE dan R^2 paling optimal, sedangkan Random Forest menempati posisi kedua. Temuan ini mengindikasikan bahwa model ensemble berbasis boosting memiliki kemampuan lebih kuat dalam memetakan hubungan kompleks antarvariabel sosial ekonomi seperti tingkat pengangguran, angka kemiskinan, rata-rata lama sekolah, dan Indeks Pembangunan Manusia (IPM).

Dengan demikian, model boosting sering menjadi pilihan utama dalam prediksi berbasis data besar.

Penelitian Fahmi (2025) juga memberikan kontribusi penting dengan menerapkan Random Forest, XGBoost, CatBoost, dan LightGBM untuk memprediksi indeks kemiskinan di Jawa Tengah. Penelitian ini menambahkan pendekatan *explainable AI* melalui SHAP, PDP, dan ALE untuk mengidentifikasi variabel yang paling berpengaruh, seperti jumlah rumah tangga, pengeluaran per kapita, dan kondisi rumah tidak layak huni. Hasil penelitian menunjukkan bahwa model ensemble tidak hanya unggul dalam akurasi prediksi, tetapi juga mampu memberikan interpretasi mendalam yang sangat penting dalam penyusunan kebijakan penanggulangan kemiskinan. Temuan ini menegaskan bahwa integrasi antara model prediktif dan interpretabilitas sangat diperlukan dalam analisis kemiskinan.

Lebih lanjut, penelitian oleh Khalik & Arifin (2023) membandingkan beberapa algoritma seperti Decision Tree, KNN, Naïve Bayes, Neural Network, dan Random Forest untuk klasifikasi indeks kedalaman kemiskinan di Sulawesi Selatan. Hasil penelitian menunjukkan bahwa Neural Network dan KNN memiliki tingkat akurasi tertinggi, sementara Random Forest tetap memberikan performa yang kompetitif. Hal ini menunjukkan bahwa pemilihan algoritma sangat bergantung pada karakteristik data serta tujuan analisis, apakah untuk klasifikasi atau prediksi numerik.

Sementara itu, Handayani & Qutub (2025) secara khusus menerapkan Random Forest untuk memprediksi persentase penduduk miskin di Kabupaten Bogor menggunakan data deret waktu dan menemukan bahwa variabel seperti akses kesehatan, pendidikan, serta kepadatan penduduk merupakan faktor yang paling berpengaruh. Random Forest terbukti mampu memodelkan pola temporal dan variasi antarwilayah sehingga efektif untuk mendukung kebijakan berbasis data.

BAB III

METODE

3.1 Pengumpulan data

Data yang digunakan dalam penelitian ini diperoleh dari Badan Pusat Statistik (BPS) melalui berbagai publikasi resmi yang tersedia pada laman *bps.go.id*. Seluruh variabel yang dianalisis merupakan data tahun 2023, sehingga bersifat cross-section, yaitu data yang menggambarkan kondisi suatu variabel pada satu titik waktu yang sama untuk berbagai wilayah. Dalam penelitian ini, unit analisis yang digunakan adalah kabupaten/kota di Indonesia. Beberapa variabel yang dikumpulkan mencakup persentase penduduk miskin, Produk Domestik Regional Bruto (PDRB), Indeks Pembangunan Manusia (IPM), Tingkat Pengangguran Terbuka (TPT), serta Rata-rata Lama Sekolah (RLS). Data cross-section ini dipilih karena dapat memberikan gambaran komparatif antarwilayah pada tahun yang sama, sehingga memungkinkan analisis hubungan antarvariabel secara lebih tepat dan representatif.

3.2 Metode Random Forest sebagai Teknik Pemodelan

Dalam penelitian ini digunakan metode Random Forest, yaitu salah satu algoritma *ensemble learning* yang bekerja dengan menggabungkan banyak pohon keputusan (*decision trees*) untuk menghasilkan model prediksi yang lebih akurat dan stabil. Random Forest termasuk ke dalam metode *bagging* (bootstrap aggregating), di mana setiap pohon dibangun menggunakan sampel data yang diambil secara acak melalui proses *bootstrap sampling*. Selain itu, pada setiap percabangan (node) dalam pohon, algoritma hanya mempertimbangkan subset acak dari variabel prediktor sehingga mengurangi risiko korelasi antar pohon dan meningkatkan performa generalisasi.

3.3 Exploratory Data Analysis (EDA)

Pada tahap Exploratory Data Analysis (EDA), dilakukan pemeriksaan awal terhadap karakteristik data untuk memahami pola, struktur, serta potensi masalah yang terdapat di dalam dataset. Analisis dimulai dengan melihat

statistik deskriptif seperti nilai minimum, maksimum, rata-rata, dan penyebaran data pada setiap variabel untuk memperoleh gambaran umum kondisi data. Selanjutnya dilakukan visualisasi melalui histogram, boxplot, dan scatterplot guna mengidentifikasi pola distribusi, hubungan antarvariabel, serta mendeteksi adanya nilai ekstrem (outlier) yang dapat memengaruhi proses pemodelan. Selain itu, dilakukan pengecekan terhadap missing value untuk memastikan tidak terdapat nilai kosong yang dapat menyebabkan error saat pemodelan. Hasil EDA menjadi dasar penting dalam menentukan langkah pra-pengolahan (preprocessing) data selanjutnya, sehingga proses analisis dan pemodelan dapat berjalan secara optimal dan akurat.

3.4 Pengecekan dan Penanganan Missing Value

Pada tahap pra-pengolahan data (preprocessing), dilakukan pengecekan nilai hilang (missing value) untuk memastikan kualitas data yang digunakan dalam proses pemodelan. Pengecekan missing value dilakukan menggunakan fungsi `.isnull().sum()` pada Python, sehingga dapat diketahui jumlah nilai kosong pada setiap variabel. Keberadaan missing value penting untuk diperhatikan karena dapat menyebabkan bias, menurunkan akurasi model, serta mengganggu proses analisis selanjutnya. Setelah dilakukan identifikasi, missing value kemudian ditangani menggunakan metode imputasi median. Metode ini dipilih karena lebih robust terhadap outlier dan mampu mempertahankan karakteristik distribusi data, terutama pada variabel ekonomi dan sosial yang cenderung memiliki sebaran tidak simetris. Dengan demikian, setelah proses imputasi selesai, seluruh variabel pada dataset berada dalam kondisi lengkap dan siap digunakan pada tahapan analisis berikutnya.

3.5 Deteksi dan penanganan Outlier

Pada tahap ini dilakukan proses deteksi outlier untuk mengidentifikasi nilai-nilai ekstrem pada variabel ekonomi yang digunakan dalam penelitian. Deteksi dilakukan menggunakan metode Interquartile Range (IQR), yaitu dengan menghitung batas bawah (lower fence) dan batas atas (upper fence) berdasarkan kuartil pertama (Q1) dan kuartil ketiga (Q3). Hasil deteksi menunjukkan adanya

beberapa observasi yang berada di luar rentang normal pada variabel seperti PDRB, kemiskinan, IPM, TPT, dan RLS. Namun, karena data penelitian ini merupakan data ekonomi dan sosial yang wajar memiliki variasi besar antar wilayah, terutama pada variabel seperti PDRB dan tingkat kemiskinan, maka keberadaan outlier tidak dihapus maupun diubah. Outlier dalam konteks data ekonomi sering kali mencerminkan kondisi nyata suatu daerah, sehingga penghapusan atau modifikasi dapat menyebabkan hilangnya informasi penting. Oleh karena itu, penelitian ini hanya melakukan deteksi outlier tanpa melakukan penanganan lanjutan, demi menjaga integritas dan representativitas data.

3.6 Standarisasi Data

Standarisasi data dilakukan untuk menyamakan skala antar variabel agar tidak ada variabel yang mendominasi proses pemodelan akibat perbedaan satuan atau rentang nilai. Proses ini menggunakan teknik *Standardization* yang mengubah setiap variabel numerik menjadi memiliki rata-rata (mean) sebesar 0 dan standar deviasi sebesar 1. Dengan demikian, seluruh variabel berada pada skala yang sama, sehingga algoritma Random Forest dapat bekerja lebih optimal. Standarisasi dilakukan setelah memastikan data bebas dari nilai hilang dan telah melalui proses eksplorasi awal.

3.7 Pembagian Data Training dan Testing

Pembagian data dilakukan untuk memisahkan data yang digunakan untuk melatih model dengan data yang digunakan untuk menguji performanya. Dalam penelitian ini, data dibagi menjadi dua bagian: 80% sebagai data training dan 20% sebagai data testing. Data training digunakan agar model dapat belajar pola hubungan antara variabel bebas dengan variabel target, sedangkan data testing digunakan untuk mengevaluasi kemampuan model dalam melakukan prediksi pada data yang belum pernah dilihat sebelumnya. Pembagian ini penting untuk menghindari *overfitting* dan memastikan bahwa model memiliki kemampuan generalisasi yang baik.

3.8 Pemodelan Random Forest

Pemodelan dilakukan menggunakan algoritma Random Forest Regression, yaitu metode *ensemble learning* yang membangun banyak pohon keputusan (decision trees) dan menggabungkan hasilnya untuk memperoleh prediksi yang lebih stabil dan akurat. Random Forest dipilih karena mampu menangani hubungan nonlinear, tidak sensitif terhadap multikolinearitas, serta memiliki performa yang baik pada data ekonomi yang memiliki variasi antar wilayah. Model awal dibangun dengan parameter dasar (default) dan kemudian dilatih menggunakan data training yang telah dipersiapkan. Output model meliputi prediksi pada data testing serta pengukuran performa menggunakan metrik seperti MAE, RMSE, dan R^2 .

3.9 Hyperparameter Tuning

Tahap selanjutnya adalah *hyperparameter tuning*, yaitu proses pencarian kombinasi parameter terbaik agar model Random Forest menghasilkan performa yang lebih optimal. Teknik yang digunakan adalah RandomizedSearchCV, yang menguji berbagai kombinasi parameter seperti jumlah pohon ($n_estimators$), kedalaman maksimum pohon (max_depth), jumlah minimal sampel pada daun ($min_samples_leaf$), dan fitur yang dipertimbangkan pada setiap pemisahan ($max_features$). Hasil tuning memberikan model terbaik yang kemudian dievaluasi kembali menggunakan data testing. Model hasil tuning kemudian dibandingkan dengan model awal untuk mengetahui peningkatan performa yang diperoleh dari proses optimasi tersebut.

BAB IV

HASIL DAN PEMBAHASAN

4.1 Exploratory Data Analysis

a. Tipe data

Pada EDA dilakukan pengecekan terhadap tipe data yang akan dibuat pemodelannya, didapatkan hasil sebagai berikut.

Tabel 1. Tipe Data

#	Column	Non-null Count	Dtype
0	Kabupaten/Kota	479 non-null	Object
1	Kemiskinan	479 non-null	Float64
2	PDRB	479 non-null	Float64
3	IPM	479 non-null	Float64
4	TPT	472 non-null	Float64
5	RLS	479 non-null	Float64

Berdasarkan pengamatan terhadap tipe data yang ada, bisa dijelaskan bahwa dataset ini terdiri dari enam kolom utama yang masing-masing memiliki tipe data dan jumlah nilai non-null yang berbeda. Kolom pertama yaitu KABUPATEN/KOTA, mencakup 479 entri dengan tipe data object. Ini menunjukkan bahwa kolom itu berisi informasi kategorikal berupa nama daerah, bukan angka, sehingga berfungsi sebagai identitas atau label untuk tiap baris data. Sedangkan lima kolom lainnya memiliki tipe numerik float64, yang berarti bahwa semua variabel tersebut adalah data kuantitatif yang dapat diproses secara statistik maupun ekonometrik. Karakteristik dari data dapat dilihat pada gambar berikut.

b. Statistik deskriptif

Tabel 2. Statistika Deskriptif

	Kemiskinan	PDRB	IPM	TPT	RLS
Count	479	479	479	472	479
Mean	10,38	42317,26	72,06	4,49	8,87
Std	5,52	89799,22	5,08	2,03	1,38
Min	2,27	308,51	57,82	0,75	5,07
25%	6,45	8012,45	68,63	2,86	7,81
50%	9,16	18025,68	71,21	4,12	8,56
75%	13,14	38318,76	74,53	5,77	9,56
max	32,29	859832	88,28	11,65	13,04

Statistik deskriptif dalam tabel tersebut memberikan ringkasan mengenai pola dari setiap variabel berdasarkan data yang tersedia. Dalam hal kemiskinan, dari total 479 pengamatan, rata-rata nilainya tercatat di angka 10.38, dengan deviasi standar 5.52, nilai terendah 2.27, median 9.16, dan nilai tertinggi mencapai 32.29, yang menunjukkan adanya variasi yang signifikan. Untuk variabel PDRB, rata-rata nilainya sekitar 42.317, tetapi deviasi standarnya sangat besar yaitu 89.799, nilai minimum tercatat 308.51, median 18.025, dan nilai maksimum mencapai 859.832, mencerminkan adanya ketidakmerataan ekonomi yang tinggi.

Indikator IPM menunjukkan nilai rata-rata 72.06 dengan deviasi standar 5.08, nilai terendah 57.82, median 71.21, dan nilai tertinggi 88.28. Hal ini mengindikasikan bahwa perbedaan IPM antara wilayah tidak begitu signifikan. Untuk variabel TPT, yang memiliki 472 data, rata-ratanya adalah 4.49, deviasi standarnya 2.03, nilai minimum 0.75, median 4.12, dan nilai maksimum 11.65, yang menunjukkan adanya variasi sedang. Di sisi lain, variabel RLS memiliki rata-rata 8.78, deviasi standar 1.38, nilai minimum 5.07, median 8.56, dan nilai maksimum 13.04, menunjukkan bahwa durasi pendidikan relatif seragam di sebagian besar wilayah.

c. Pengecekan missing value

Kabupaten/Kota	0
Kemiskinan	0
PDRB	0
IPM	0
TPT	7
RLS	0

Hasil pemeriksaan mengenai jumlah nilai yang hilang di tabel menunjukkan bahwa hampir semua variabel dalam dataset memiliki data yang lengkap tanpa adanya kekosongan. Kolom KABUPATEN/KOTA, KEMISKINAN, PDRB, IPM, dan RLS menunjukkan nilai nol pada jumlah nilai yang hilang, yang menandakan bahwa semua entri dalam kolom-kolom tersebut terisi sepenuhnya dan tidak ada data yang hilang. Situasi ini sangat menguntungkan karena menjamin bahwa analisis yang akan dilakukan pada variabel-variabel tersebut dapat dilakukan tanpa adanya masalah terkait dengan kelengkapan data.

Satu-satunya variabel yang mengalami masalah adalah TPT, dengan tujuh baris data yang hilang. Ketidakhadiran tujuh data ini menunjukkan bahwa informasi mengenai tingkat pengangguran terbuka tidak terdaftar atau tidak tersedia di beberapa wilayah.


d. Penanganan missing value

Pada variabel TPT dilakukan dengan metode imputasi median. Metode ini dipilih karena median lebih tahan terhadap nilai ekstrem dibandingkan rata-rata, sehingga dapat memberikan perkiraan yang lebih stabil dan akurat mengenai kondisi sebenarnya. Karena hanya ada tujuh data yang hilang dalam variabel ini, penggunaan median memungkinkan pengisian yang konsisten tanpa menyebabkan distorsi signifikan pada distribusi data.

Kabupaten/Kota	0
Kemiskinan	0
PDRB	0
IPM	0
TPT	0
RLS	0

Hasil pengecekan ulang setelah proses imputasi menunjukkan bahwa semua variabel dalam dataset kini terbebas sepenuhnya dari nilai yang hilang. Setiap kolom, mulai dari KABUPATEN/KOTA, KEMISKINAN, PDRB, IPM, TPT, hingga RLS, tercatat tidak ada nilai yang hilang. Hal ini menunjukkan bahwa dataset sudah dalam kondisi lengkap dan siap dipergunakan untuk berbagai analisis tanpa kendala terkait data yang hilang. Tidak adanya nilai yang hilang pada variabel TPT membuktikan bahwa pengisian dengan menggunakan nilai median telah dilakukan dengan baik dan telah menyamakan jumlah pengamatan di seluruh variabel.

e. Visualisasi distribusi data



Gambar 1. Visualisasi distribusi data


Visualisasi penyebaran data menunjukkan pola yang berbeda untuk masing-masing variabel. Kemiskinan memiliki distribusi yang cenderung condong ke kanan, dengan konsentrasi terbanyak berada pada kisaran lima hingga sepuluh persen, menunjukkan bahwa sebagian besar daerah berada pada

tingkat kemiskinan sedang. PDRB terlihat sangat terdistribusi dengan ekor panjang ke arah kanan, mengindikasikan adanya perbedaan ekonomi yang signifikan antar wilayah, karena hanya sedikit daerah yang memiliki PDRB yang sangat tinggi. IPM menunjukkan distribusi yang lebih terpusat dan mendekati pola normal, dengan sebagian besar nilai terletak pada rentang 68 hingga 75, mencerminkan kondisi pembangunan manusia yang cukup seragam. TPT menunjukkan pola yang cenderung miring ke kanan dengan frekuensi terbesar di kisaran tiga hingga lima persen, menunjukkan adanya variasi pengangguran yang masih dalam batas moderat. Di sisi lain, RLS menunjukkan distribusi yang paling stabil dan mendekati normal, dengan sebagian besar lama sekolah berada di antara delapan hingga sembilan tahun. Secara keseluruhan, grafik ini menunjukkan bahwa beberapa variabel memiliki penyebaran yang luas, sementara yang lainnya lebih konsisten, dan data telah berada dalam kondisi siap untuk analisis lebih lanjut.

4.2 Pemodelan Tanpa Penanganan Outlier

a. Visualisasi data (Boxplot)

Pada tahap ini, proses pemodelan dilakukan tanpa menghilangkan outlier. Keputusan ini diambil karena outlier dianggap sebagai bagian penting dari karakter asli data ekonomi, dan algoritma Random Forest cukup dalam menangani nilai ekstrem, sehingga penampilan visualisasinya data adalah sebagai berikut.



Gambar 2. Visualisasi data Boxplot

Variabel PDRB memperlihatkan pola outlier yang paling ekstrem dibandingkan variabel lain. Sumbu vertikal menunjukkan bahwa nilai PDRB di beberapa daerah berada sangat jauh di atas kelompok data utama, bahkan secara visual tampak melonjak hingga ratusan ribu hingga mendekati satu juta satuan. Kondisi ini menunjukkan adanya perbedaan kapasitas ekonomi antardaerah yang sangat besar. Mayoritas wilayah memiliki nilai PDRB yang jauh lebih rendah, sedangkan beberapa wilayah tertentu memiliki aktivitas ekonomi yang begitu besar hingga muncul sebagai outlier yang signifikan. Ketidakseimbangan ini membuat distribusi PDRB memiliki ekor yang sangat panjang dan tidak simetris.


Untuk variabel IPM, persebarannya tampak lebih stabil dengan rentang nilai yang tidak terlalu lebar. Outlier muncul dalam jumlah terbatas, namun perbedaannya tidak terlalu ekstrem. Titik-titik tersebut menunjukkan bahwa ada beberapa daerah dengan pencapaian pembangunan manusia yang jauh lebih tinggi atau lebih rendah dibandingkan mayoritas daerah lain, tetapi variasinya masih dalam batas yang wajar. Rentang nilai antar kuartil juga relatif sempit, menandakan bahwa mayoritas daerah memiliki tingkat IPM yang serupa.

Pada variabel TPT, terlihat bahwa data terdistribusi cukup merata namun terdapat beberapa outlier di bagian atas, menunjukkan adanya daerah dengan tingkat pengangguran yang lebih tinggi dari pola umum. Meskipun demikian, whisker bawah dan atas tidak terlalu panjang, sehingga variasi nilai TPT tidak sebesar variabel seperti PDRB atau kemiskinan. Ini menggambarkan bahwa perbedaan tingkat pengangguran antarwilayah cenderung moderat, meskipun ada beberapa daerah yang mengalami tekanan pasar kerja lebih berat.

Variabel RLS menampilkan pola yang juga relatif stabil, dengan rentang yang tidak terlalu melebar. Munculnya outlier di bagian atas dan bawah menunjukkan adanya daerah dengan lama sekolah yang jauh lebih rendah maupun lebih tinggi dibandingkan mayoritas wilayah. Namun secara

umum, persebaran nilai berada dalam batas yang cukup rapat, menandakan bahwa tingkat pendidikan dasar hingga menengah relatif seragam di sebagian besar daerah.

b. Visualisasi Matriks Korelasi



Gambar 3. Visualisasi Matriks Korelasi

Pola hubungan yang terlihat menunjukkan interaksi yang berkaitan antara tingkat kemiskinan, situasi ekonomi daerah, mutu pembangunan manusia, tingkat pengangguran, dan rata-rata durasi pendidikan. Salah satu koneksi yang paling kuat adalah hubungan antara IPM dan RLS, yang menunjukkan nilai korelasi yang signifikan. Ini menunjukkan bahwa semakin tinggi rata-rata lama pendidikan penduduk, semakin baik pula indeks pembangunan manusia di suatu daerah. Temuan ini sejalan dengan pemahaman umum bahwa pendidikan adalah dasar utama dalam meningkatkan kualitas hidup dan pengembangan manusia secara keseluruhan.

Hubungan yang kuat lainnya adalah antara Indeks Pembangunan Manusia (IPM) dan Tingkat Pengangguran Terbuka (TPT), yang menunjukkan bahwa daerah dengan tingkat pembangunan manusia yang lebih tinggi

biasanya memiliki tingkat pengangguran yang lebih rendah. Situasi ini menunjukkan bahwa peningkatan kualitas pendidikan, kesehatan, dan standar hidup dapat membantu masyarakat lebih mudah diterima di pasar kerja. Selain itu, terdapat hubungan yang cukup signifikan antara Rata-rata Lama Sekolah (RLS) dan TPT, yang menunjukkan bahwa durasi pendidikan seseorang dapat memengaruhi kemungkinan mereka untuk memperoleh pekerjaan yang lebih stabil. Ketiganya menunjukkan adanya keterkaitan yang erat dalam konteks pengembangan sumber daya manusia. Di sisi lain, variabel kemiskinan menunjukkan keterkaitan negatif dengan sebagian besar variabel lainnya. Korelasi negatif yang cukup signifikan dengan IPM menunjukkan bahwa daerah yang memiliki pembangunan manusia yang baik cenderung mengalami tingkat kemiskinan yang lebih rendah. Keterkaitan negatif dengan RLS mengindikasikan bahwa peningkatan kualitas pendidikan berperan dalam mengurangi angka kemiskinan. Pola ini semakin menegaskan bahwa pendidikan dan kualitas hidup memainkan peran krusial dalam memutus siklus kemiskinan. Meskipun hubungan antara kemiskinan dan PDRB serta TPT tidak sekuat variabel lainnya, arah hubungan tetap konsisten, yakni menunjukkan bahwa pertumbuhan ekonomi dan penurunan angka pengangguran dapat mendukung penurunan tingkat kemiskinan.

Sementara itu, PDRB menunjukkan hubungan positif yang sedang dengan IPM, TPT, dan RLS, yang menunjukkan bahwa daerah dengan ekonomi yang lebih tangguh cenderung memiliki kualitas pembangunan manusia yang lebih baik, pendidikan yang lebih tinggi, dan tingkat pengangguran yang relatif lebih terkendali. Keterkaitan ini mencerminkan bagaimana perkembangan ekonomi dan pembangunan manusia berlangsung bersamaan, meskipun kekuatannya tidak sekuat hubungan antara variabel sosial lainnya.

c. Standarisasi Data

Hasil dari data setelah di Standarisasi adalah sebagai berikut.

Tabel 3. Hasil Standarisasi Data

	Kabupaten/Kota	Kemiskinan	PDRB	IPM	TPT	RLS
0	Simeuleu	1.366314	-0.439017	-0.787296	0.677125	0.741105
1	Aceh Singkil	1.589235	-0.436036	-0.378015	1.169364	-0.062792
2	Aceh Selatan	0.311516	-0.394110	-0.712524	0.120249	0.089297
3	Aceh Tenggara	0.374948	-0.401975	-0.198955	0.254496	0.943889
4	Aceh Timur	0.545311	-0.317865	-0.539367	1.761045	-0.229365
...	...	...	...	...	...	...
474	Teluk Wandama	3.356295	-0.452231	-2.044655	-0.854284	-1.098442
475	Teluk Bintuni	3.236679	-0.030953	-1.192642	-0.481376	-0.203096
476	Manokwari	1.513116	-0.353041	0.226067	0.736791	-0.178669
477	Manokwari Selatan	3.156934	-0.461397	-2.068267	-0.180563	-1.322954
478	Pegunungan Arfak	3.970688	-0.468297	-2.802218	-0.180563	-2.373089

Data yang telah distandarisasi ini memberikan gambaran menyeluruh mengenai kondisi sosial-ekonomi dari 479 kabupaten/kota di Indonesia melalui lima indikator utama, yaitu kemiskinan, PDRB, IPM, TPT, dan RLS. Karena seluruh variabel telah dinormalisasi, setiap nilai tidak lagi menunjukkan angka absolut, melainkan posisi relatif suatu daerah dibandingkan rata-rata nasional. Nilai yang lebih tinggi menunjukkan kondisi yang lebih baik untuk variabel positif seperti IPM dan RLS, namun mengindikasikan kondisi yang lebih buruk untuk variabel seperti kemiskinan dan TPT yang secara konseptual bersifat negatif. Dengan demikian, pola perbedaan antarwilayah dapat dibaca lebih jelas tanpa dipengaruhi oleh skala asli data.

d. Data training dan data testing

Hasil dari data training dan data testing memiliki nilai sebagai berikut.

Jumlah data total	: 479
Jumlah data training	: 383
Jumlah data testing	: 96

Jumlah data pelatihan yang mencapai 383 baris memberikan kesempatan pada model untuk mengenali beragam karakteristik sosial-ekonomi setiap kabupaten atau kota yang terdapat dalam dataset, termasuk aspek kemiskinan, PDRB, IPM, tingkat pengangguran, serta rata-rata lama pendidikan. Semakin banyak data yang tersedia untuk pelatihan, semakin tinggi kemungkinan model dapat memahami hubungan yang rumit antara variabel, khususnya ketika data meliputi kawasan dengan perbedaan signifikan dalam pembangunan. Dengan keragaman wilayah di Indonesia yang sangat luas, jumlah data pelatihan yang besar menjadi hal yang krusial untuk memastikan bahwa model tidak hanya mengidentifikasi pola dari area tertentu, tetapi juga dapat mengenali pola yang lebih umum di seluruh daerah.

Sementara itu, 96 data uji yang dipisahkan dari proses pelatihan memainkan peranan penting dalam menguji seberapa baik model dapat menggeneralisasi. Data ini digunakan untuk mengevaluasi kemampuan model dalam melakukan prediksi terhadap data yang tidak pernah dilihat sebelumnya. Jumlah tersebut cukup untuk memberikan evaluasi yang konsisten dan dapat diandalkan, karena mencakup sekitar 20 persen dari total pengamatan dan mencerminkan berbagai kondisi sosial-ekonomi dari daerah yang berbeda di Indonesia. Jika model menunjukkan hasil yang baik pada data uji sebanyak ini, maka dapat disimpulkan bahwa model tersebut memiliki potensi yang kuat untuk penerapan dalam analisis prediktif di kehidupan nyata.

e. Pemodelan

MAE	: 0,6133
RMSE	: 0,8178
R^2	: 0,3606

Nilai MAE yang tercatat sebesar 0. 61 menunjukkan bahwa rata-rata kesalahan absolut antara nilai yang diramalkan oleh model dan nilai yang

sebenarnya sekitar 0. 61 satuan standar. Mengingat data yang digunakan telah mengalami proses standardisasi, angka ini menunjukkan bahwa setiap prediksi rata-rata menyimpang sedikit lebih dari setengah satuan deviasi dari nilai aktual. Nilai ini menunjukkan bahwa meskipun model dapat menangkap beberapa pola dasar dari data, masih ada tingkat kesalahan yang cukup signifikan dalam prediksinya.

Nilai RMSE yang mencapai 0,81 menunjukkan bahwa kesalahan pada model relatif lebih signifikan jika kita mempertimbangkan bahwa RMSE cenderung memberikan fokus lebih pada kesalahan yang jauh dari nilai sebenarnya dibandingkan dengan MAE. Nilai ini mengindikasikan adanya beberapa prediksi yang sangat berbeda dari nilai yang seharusnya, sehingga menandakan bahwa model belum sepenuhnya dapat menggambarkan hubungan rumit antar variabel dalam dataset.

Sementara itu, nilai R^2 sebesar 0. 36 memberikan gambaran yang lebih umum mengenai seberapa baik model dapat menjelaskan variasi dalam data. Dengan angka tersebut, model ini hanya dapat menguraikan sekitar 36 persen dari variasi yang ada pada variabel tujuan berdasarkan variabel yang digunakan untuk prediksi. Artinya, lebih dari setengah variasi data belum dapat dijelaskan oleh model ini, yang menunjukkan kemungkinan adanya hubungan non-linier, interaksi antar variabel yang belum terdeteksi, atau kurangnya informasi dalam variabel prediktor yang dipilih.

f. **Hyperparameter Tuning**

Hyperparameter Tuning adalah proses mencari kombinasi nilai parameter terbaik pada suatu algoritma *machine learning* agar kinerja model menjadi optimal. Dengan melakukan tuning pada data, maka model yang dihasilkan adalah sebagai berikut.

MAE	: 0,6016
RMSE	: 0,7878
R^2	: 0,4066

Nilai MAE yang saat ini tercatat di angka 0.60 menunjukkan bahwa rata-rata kesalahan absolut antara prediksi dan data aktual telah berhasil dikurangi lebih signifikan dibanding sebelumnya. Penurunan ini menunjukkan bahwa model semakin efektif dalam mengurangi deviasi prediksi secara konsisten pada sebagian besar data, sehingga tingkat akurasi prediksi menunjukkan kemajuan meskipun perubahan yang terjadi tidak terlalu besar secara angka.

Nilai RMSE yang turun menjadi 0.78 juga mengonfirmasi bahwa model telah berhasil mengurangi kesalahan prediksi yang bersifat besar atau ekstrem. Karena RMSE memberi bobot lebih tinggi pada kesalahan yang besar, penurunan nilai ini menunjukkan bahwa tuning membantu model dalam mengurangi prediksi yang jauh meleset dari nilai sebenarnya. Hal ini menandakan bahwa model pasca-tuning tidak hanya memberikan prediksi yang lebih tepat secara umum, tetapi juga lebih stabil dalam menghadapi variasi data yang lebih besar atau pola yang lebih sulit ditangkap sebelumnya.

Peningkatan paling mencolok terlihat pada nilai R^2 yang naik menjadi 0.40. Angka ini menunjukkan bahwa model sekarang mampu menjelaskan sekitar 40 persen variasi data target, meningkat cukup signifikan dari kondisi sebelum tuning. Peningkatan R^2 ini mengindikasikan bahwa parameter yang disesuaikan melalui proses tuning berhasil membantu model menangkap hubungan yang lebih kompleks antara variabel prediktor dan variabel target. Dengan kata lain, model kini memiliki pemahaman yang lebih baik mengenai struktur data dan mampu mencerminkan pola yang lebih akurat daripada versi sebelumnya.

4.3 Pemodelan dengan Penanganan Outlier

a. Pengecekan Outlier

Pada tahap ini dilakukan identifikasi outlier pada setiap variabel penelitian untuk mengetahui keberadaan nilai ekstrem yang berpotensi memengaruhi

proses pemodelan. Jumlah dari Outlier tiap variabel dapat dilihat pada tabel berikut.

Kemiskinan	→ jumlah outlier : 17
PDRB	→ jumlah outlier : 51
IPM	→ jumlah outlier : 16
TPT	→ jumlah outlier : 4
RLS	→ jumlah outlier : 4

Variabel PDRB memiliki jumlah outlier terbanyak, yaitu 51, yang menandakan adanya perbedaan ekstrem dalam tingkat aktivitas ekonomi antar kabupaten/kota. Kemiskinan dan IPM juga menampilkan variasi tinggi dengan masing-masing 17 dan 16 outlier, mengindikasikan bahwa kesejahteraan dan kualitas pembangunan manusia di Indonesia masih sangat tidak merata. Sementara itu, variabel TPT dan RLS hanya memiliki empat outlier, menunjukkan bahwa penyimpangan ekstrem pada tingkat pengangguran maupun rata-rata lama sekolah relatif lebih kecil dibanding variabel ekonomi.

b. Penanganan Outlier

Penanganan outlier dilakukan dengan menggunakan metode winsorizing sebagai upaya menjaga kualitas data tanpa harus menghapus observasi yang bernilai ekstrem. Hasil dari penanganan itu adalah sebagai berikut.


Kemiskinan	→ jumlah outlier : 0
PDRB	→ jumlah outlier : 0
IPM	→ jumlah outlier : 0
TPT	→ jumlah outlier : 0
RLS	→ jumlah outlier : 0

Variabel penelitian yaitu KEMISKINAN, PDRB, IPM, TPT, dan RLS menyiratkan bahwa tidak ada nilai ekstrem yang terdeteksi pada setiap variabel, yang terlihat dari jumlah outlier yang bernilai nol di setiap kasus. Situasi ini menunjukkan bahwa distribusi data berada dalam batas yang

normal dan tidak ada pengamatan yang menyimpang secara signifikan dari pola yang ada.

c. Visualisasinya data (Boxplot)

Visualisasi boxplot digunakan untuk menggambarkan distribusi data setelah penanganan outlier serta memastikan bahwa nilai ekstrem telah berada dalam batas yang wajar. Hasil visualisasi dari BoxPlot adalah sebagai berikut.




Gambar 4. Visualisasi Boxplot (penanganan outlier)

Menunjukkan bahwa semua variable KEMISKINAN, PDRB, IPM, TPT, dan RLS telah berada dalam batas distribusi yang wajar tanpa kehadiran nilai ekstrem yang melampaui batas whisker. Pada variabel KEMISKINAN, penyebaran data tampak stabil dengan median yang berada di sekitar titik tengah, menunjukkan bahwa variasi berada dalam kontrol. Sebelumnya, variabel PDRB yang berisiko menghasilkan nilai ekstrem kini terlihat lebih baik dalam penyebarannya, tercermin dari whisker yang mencakup seluruh data tanpa adanya titik yang menyimpang. Begitu juga, IPM menunjukkan pola distribusi yang mulus dan teratur, dengan median yang kuat di tengah distribusi dan tanpa pengamatan yang keluar dari batas normal statistik. Variabel TPT, yang dulunya memiliki potensi variasi yang besar, kini juga menunjukkan distribusi yang bersih dari outlier, dengan penyebaran yang simetris dan median yang merefleksikan keadaan umum. Di sisi lain, variabel RLS menunjukkan

rentang variasi yang wajar tanpa nilai ekstrem yang mengganggu struktur data, menandakan bahwa proses pembersihan telah menghasilkan distribusi data pendidikan yang lebih representatif. Sementara itu visualisasi Korelasi dapat dilihat pada gambar berikut.

d. Visualisasi Matriks Korelasi

Matriks korelasi disajikan untuk melihat kembali pola hubungan antarvariabel setelah proses penanganan outlier dilakukan.



Gambar 5. Visualisasi Matriks Korelasi (penanganan outlier)

Matriks korelasi tersebut menunjukkan pola hubungan yang saling terkait antarvariabel sosial-ekonomi, di mana setiap koefisien memberikan gambaran mengenai arah dan kekuatan asosiasi antarindikator. Terlihat bahwa variabel KEMISKINAN memiliki hubungan negatif dengan hampir seluruh variabel lainnya, terutama dengan IPM yang menunjukkan korelasi sebesar -0.582 . Hal ini menegaskan bahwa semakin tinggi kualitas pembangunan manusia suatu wilayah, semakin rendah tingkat kemiskinan yang terjadi, sebuah hubungan yang logis mengingat peningkatan pendidikan, kesehatan, dan standar hidup biasanya menurunkan kerentanan terhadap kemiskinan. Hubungan negatif KEMISKINAN dengan PDRB dan RLS juga memperlihatkan kecenderungan bahwa pertumbuhan

ekonomi serta peningkatan rata-rata lama sekolah berkontribusi pada pengurangan tingkat kemiskinan, meskipun kekuatan korelasinya tidak sebesar dengan IPM.

Sebaliknya, variabel IPM menunjukkan korelasi positif yang kuat dengan RLS sebesar 0.831, yang mencerminkan peran pendidikan sebagai salah satu pilar utama dalam pembentukan indeks pembangunan manusia. Korelasi positif lainnya tampak antara IPM dengan TPT dan PDRB, yang mengisyaratkan bahwa wilayah dengan kualitas pembangunan manusia yang lebih baik cenderung memiliki dinamika ekonomi dan pasar tenaga kerja yang lebih aktif. Pada sisi lain, variabel PDRB juga menunjukkan hubungan positif dengan TPT dan RLS, yang dapat menggambarkan bahwa daerah yang lebih produktif secara ekonomi umumnya memiliki akses pendidikan lebih tinggi serta struktur ketenagakerjaan yang lebih beragam.

e. Standarisasi Data

Proses standarisasi data dilakukan untuk menyamakan skala antarvariabel sehingga seluruh indikator memiliki kontribusi yang proporsional dalam analisis, terutama ketika variabel-variabel tersebut memiliki satuan dan rentang nilai yang berbeda jauh.

Tabel 5. Hasil Standarisasi Data (penanganan outlier)

	Kabupaten/Kota	Kemiskinan	PDRB	IPM	TPT	RLS
0	Simeuleu	1.514038	-0.959463	-0.798981	0.687955	0.746935
1	Aceh Singkil	1.756259	-0.948937	-0.380056	1.185504	-0.061439
2	Aceh Selatan	0.367919	-0.800895	-0.722447	0.125072	0.091497
3	Aceh Tenggara	0.436844	-0.828666	-0.196777	0.260767	0.950850
4	Aceh Timur	0.621956	-0.531667	-0.545209	1.783568	-0.228940
...	...	...	...	...	...	...
474	Teluk Wandama	2.547417	-1.006122	-2.085966	-0.859974	-1.102858
475	Teluk Bintuni	2.547417	0.481437	-1.213877	-0.483043	-0.199809
476	Manokwari	1.673550	-0.655878	0.238260	0.748264	-0.177961
477	Manokwari Selatan	2.547417	-1.038489	-2.110134	-0.178986	-1.328620
478	Pegunungan Arfak	2.547417	-1.062853	-2.464106	-0.178986	-2.384604

Hasil standarisasi data menunjukkan bahwa semua variabel telah berhasil diubah ke dalam skala yang seragam, sehingga setiap indikator kini memiliki nilai yang bebas dari dimensi dengan rata-rata nol dan deviasi standar satu. Nilai positif pada variabel yang telah distandarisasi menunjukkan bahwa kabupaten atau kota tersebut berada di atas rata-rata nasional untuk indikator tertentu. Sementara itu, nilai negatif mengindikasikan posisinya berada di bawah rata-rata. Contohnya, Kabupaten Simeulue memiliki nilai positif pada variabel kemiskinan dan TPT, yang artinya tingkat kemiskinan serta pengangguran di daerah tersebut lebih tinggi dibandingkan dengan rata-rata nasional. Sebaliknya, nilai negatif pada PDRB dan IPM mengindikasikan bahwa kondisi ekonomi serta kualitas pembangunan manusia di daerah tersebut lebih rendah dari rata-rata. Di sisi lain, kabupaten lain seperti Aceh Selatan menunjukkan struktur yang lebih seimbang, di mana nilai kemiskinan dan TPT mendekati nol, yang menunjukkan bahwa wilayah tersebut berada dalam kisaran yang cukup dekat dengan rata-rata nasional.

f. Data traning dan data testing

Data kemudian dibagi menjadi data training dan data testing untuk keperluan pelatihan model serta evaluasi performa prediksi. Hasil dari data traning dan data testing memiliki nilai sebagai berikut.

Jumlah data total	: 479
Jumlah data training	: 383
Jumlah data testing	: 96

Jumlah data pelatihan yang mencapai 383 baris memberikan kesempatan pada model untuk mengenali beragam karakteristik sosial-ekonomi setiap kabupaten atau kota yang terdapat dalam dataset, termasuk aspek kemiskinan, PDRB, IPM, tingkat pengangguran, serta rata-rata lama pendidikan. Semakin banyak data yang tersedia untuk pelatihan, semakin tinggi kemungkinan model dapat memahami hubungan yang rumit antara variabel, khususnya ketika data meliputi kawasan dengan perbedaan

signifikan dalam pembangunan. Dengan keragaman wilayah di Indonesia yang sangat luas, jumlah data pelatihan yang besar menjadi hal yang krusial untuk memastikan bahwa model tidak hanya mengidentifikasi pola dari area tertentu, tetapi juga dapat mengenali pola yang lebih umum di seluruh daerah.

Sementara itu, 96 data uji yang dipisahkan dari proses pelatihan memainkan peranan penting dalam menguji seberapa baik model dapat menggeneralisasi. Data ini digunakan untuk mengevaluasi kemampuan model dalam melakukan prediksi terhadap data yang tidak pernah dilihat sebelumnya. Jumlah tersebut cukup untuk memberikan evaluasi yang konsisten dan dapat diandalkan, karena mencakup sekitar 20 persen dari total pengamatan dan mencerminkan berbagai kondisi sosial-ekonomi dari daerah yang berbeda di Indonesia. Jika model menunjukkan hasil yang baik pada data uji sebanyak ini, maka dapat disimpulkan bahwa model tersebut memiliki potensi yang kuat untuk penerapan dalam analisis prediktif di kehidupan nyata.

g. Pemodelan (Penanganan Outlier)

Setelah melakukan training dan testing terhadap data, dilakukan pemodelan random forest menggunakan data yang telah melalui proses penanganan outlier untuk mengevaluasi pengaruh pembersihan nilai ekstrem terhadap performa model. Model yang dibentuk adalah sebagai berikut.

	Tanpa Outlier	Outlier
MAE	0,6323	0,6133
RMSE	0,8274	0,8178
R^2	0,3374	0,3606

Hasil pemodelan menunjukkan bahwa model Random Forest yang dibangun tanpa penanganan outlier memiliki performa yang lebih baik dibandingkan model dengan penanganan outlier. Hal ini tercermin dari nilai kesalahan prediksi yang lebih rendah serta kemampuan model yang lebih baik dalam menjelaskan variasi tingkat kemiskinan. Temuan ini

mengindikasikan bahwa nilai ekstrem pada data sosial-ekonomi berperan dalam membentuk pola hubungan antarvariabel.

Pada data kabupaten/kota di Indonesia yang bersifat heterogen, keberadaan outlier merupakan kondisi yang wajar dan mencerminkan perbedaan nyata antarwilayah. Oleh karena itu, penghapusan atau pembatasan nilai ekstrem berpotensi mengurangi representativitas data dan menurunkan kemampuan model dalam menggambarkan kondisi sosial-ekonomi secara komprehensif.

h. Hyperparameter Tuning

Dengan melakukan tuning pada data, maka model yang dihasilkan adalah sebagai berikut.

	Tanpa Oulier	Outlier
MAE	0,6407	0,6016
RMSE	0,8172	0,7878
R^2	0,3537	0,4066

Proses hyperparameter tuning meningkatkan performa model pada kedua pendekatan pemodelan. Namun, hasil tuning menunjukkan bahwa model tanpa penanganan outlier tetap memberikan kinerja yang lebih baik, ditunjukkan oleh penurunan nilai error serta peningkatan nilai koefisien determinasi. Hal ini menunjukkan bahwa penyesuaian parameter mampu memperbaiki kemampuan model dalam menangkap hubungan yang lebih kompleks antarvariabel.

4.4 Kesimpulan

Berdasarkan hasil penelitian, model machine learning yang dibangun untuk memprediksi tingkat kemiskinan berhasil menunjukkan bahwa variabel sosial ekonomi seperti TPT, RLS, PDRB, dan IPM memiliki pengaruh penting terhadap perubahan tingkat kemiskinan suatu daerah. Model regresi memberikan gambaran hubungan antar variabel, sedangkan model klasifikasi mampu mengelompokkan wilayah berdasarkan kategori tingkat kemiskinan

dengan akurasi yang cukup baik. Perbandingan analisis menunjukkan bahwa ketika outlier ditangani, performa model memang cenderung meningkat, error menurun, dan hubungan antar variabel terlihat lebih stabil. Namun, dalam konteks data sosial ekonomi, keberadaan outlier merupakan hal yang wajar karena kondisi ekstrem seperti daerah yang sangat miskin atau sangat maju memang nyata terjadi di lapangan. Oleh karena itu, penanganan outlier justru berpotensi menghilangkan informasi penting yang mencerminkan realitas data. Dengan demikian, meskipun secara teknis pembersihan outlier dapat meningkatkan performa model, pendekatan yang lebih tepat dalam penelitian ini adalah tetap mempertahankan outlier agar model mampu merepresentasikan kondisi sebenarnya di lapangan dan menghasilkan interpretasi yang lebih realistis serta relevan.

DAFTAR PUSTAKA

- Ardian, R., Syahputra, M., & Desmawan, D. (2022). Pengaruh pertumbuhan ekonomi terhadap tingkat pengangguran terbuka di Indonesia. *Jurnal Ekonomi, Bisnis Dan Manajemen*, 1(3), 190-198.
- Ernawati, A., Khairul, Sitorus, Z., Iqbal, M., & Nasution, D. (2025). *Penerapan data mining untuk klasifikasi penduduk miskin di Kabupaten Labuhanbatu menggunakan Random Forest dan K-Nearest Neighbors*. *Bulletin of Information Technology (BIT)*, 6(2), 23–35. <https://doi.org/10.47065/bit.v5i2.1783>
- Fahmi, W. F., & Fahmi, A. (2025). *Explainable machine learning for poverty prediction in Central Java regencies and cities*. *Sinkron: Jurnal dan Penelitian Teknik Informatika*, 9(4), 2080–2095. <https://doi.org/10.33395/sinkron.v9i4.15312>
- Handayani, D. N., & Qutub, S. (2025). *Penerapan Random Forest untuk prediksi dan analisis kemiskinan*. *Journal of Artificial Intelligence and Digital Business (RIGGS)*, 4(2), 405–412. <https://doi.org/10.31004/riggs.v4i2.512>
- Hasibuan, R. R. A., Kartika, A., Suwito, F. A., & Agustin, L. (2022). Pengaruh Produk Domestik Regional Bruto (PDRB) terhadap Tingkat Kemiskinan Kota Medan. *Reslaj: Religion Education Social Laa Roiba Journal*, 4(3), 683-693.
- Khalik, M. F. M., & Arifin, F. (2023). *Klasifikasi indeks kedalaman kemiskinan Provinsi Sulawesi Selatan berbasis Decision Tree, K-Nearest Neighbor, Naïve Bayes, Neural Network, dan Random Forest*. *JEPIN (Jurnal Edukasi dan Penelitian Informatika)*, 9(2), 282–289.
- Pratama, Z. B. P., & Astuti, Y. P. (2025). *Perbandingan metode machine learning (Linear Regression, Random Forest, dan XGBoost) dalam memprediksi kemiskinan di Jawa Tengah tahun 2024*. *Sistemasi: Jurnal Sistem Informasi*, 14(5), 2492–2499.

- Putriana, R., & Aji, R. H. S. (2022). Studi atas kemiskinan, tingkat partisipasi angkatan kerja, rata-rata lama sekolah sebagai penentu pertumbuhan ekonomi di Provinsi DI Yogyakarta. *Ekonomica Sharia: Jurnal Pemikiran Dan Pengembangan Ekonomi Syariah*, 8(1), 31-48.
- Siswati, E., & Hermawati, D. T. (2018). Analisis indeks pembangunan manusia (IPM) Kabupaten Bojonegoro. *Jurnal Ilmiah Sosio Agribis*, 18(2).
- Zahrawati, F. (2020). Pembebasan jerat feminisasi kemiskinan. *ALMAARIEF*, 9-16.

PROSES Pengerjaan Project

Tulus	:	• Mencari data variabel IPM untuk seluruh kabupaten/kota di indonesia pada web bps go.id. • Dalam proses pengerjaan laporan bertanggungjawab menuliskan abstrak dan latar belakang project. • Merevisi bagian abstrak
Ersa	:	• Mencari data variabel Kemiskinan, variabel TPT, dan Variabel RLS untuk seluruh kabupaten/kota di indonesia pada web bps go.id. • Mengerjakan seluruh bagian analisis data menggunakan Python, yang meliputi proses eksplorasi data (EDA), pengecekan dan penanganan missing value, pengecekan dan penanganan outlier, standarisasi data, visualisasi, pemodelan, tuning, serta evaluasi. • Dalam proses pengerjaan laporan bertanggungjawab menuliskan Tinjauan Pustaka, dan metode penitian. • Merevisi gambar SS an menjadi Tabel
Adam	:	• Mencari data variabel PDRB untuk seluruh kabupaten/kota di indonesia pada web bps go.id • Merevisi Bagian eksplorasi data (EDA) pada phyton untuk tidak dilakukan penanganan outlier karna menggunakan data ekonomi, saran dari bu laila. • Dalam proses pengerjaan laporan bertanggungjawab menuliskan Hasil pembahasan, dan kesimpulan. • Merevisi bagian hasil dan pembahasan